Projet Analyse de Donnée

FERRERE HOAREAU Anthony et CALLIS Guilhem

2024-12-26

R Markdown

Chargement du jeux de donnée: Décrivez l'ensemble du jeu de données en précisant la nature des variables

Le chargement a nécessité le package : ggplot2

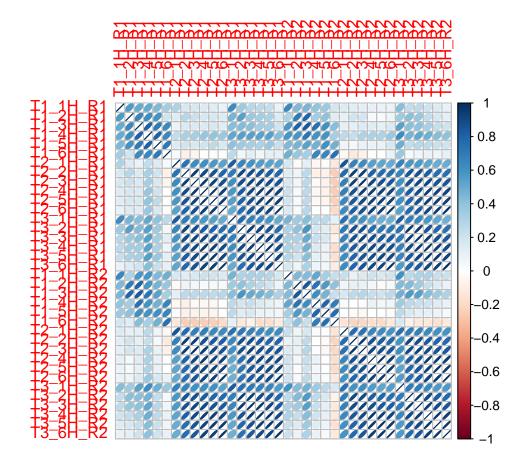
```
'data.frame':
                    542 obs. of 39 variables:
  $ T1_1H_R1: num
                    -0.205 -0.62 0.309 0.192 0.108 ...
   $ T1 2H R1: num
                     -0.689 -0.856 0.817 0.148 0.288 ...
## $ T1_3H_R1: num
                     -0.1811 -0.0211 -0.5615 0.2424 -0.1975 ...
  $ T1 4H R1: num
                     -0.06657 -0.14456 0.18148 0.56182 -0.00155 ...
  $ T1_5H_R1: num
##
                     0.5217 0.4934 -0.337 0.0453 -0.2274 ...
   $ T1_6H_R1: num
                     0.448 0.454 -0.373 -0.635 -0.571 ...
## $ T2_1H_R1: num
                     -0.449 -0.572 -0.209 0.526 0.34 ...
  $ T2 2H R1: num
                     -1.5144 -1.4755 -1.29 1.4315 -0.0468 ...
   $ T2_3H_R1: num
##
                     -3.815 -3.079 -2.633 1.842 -0.327 ...
##
   $ T2 4H R1: num
                    -2.5 -2.22 -2.4 1.83 -0.47 ...
## $ T2_5H_R1: num
                    -2.9144 -2.2659 -2.4397 1.9242 0.0153 ...
   $ T2_6H_R1: num
                     -3.57 -3.36 -2.03 2.19 2.17 ...
##
   $ T3_1H_R1: num
                     -0.6645 -0.5427 -0.2709 0.4127 -0.0402 ...
##
   $ T3_2H_R1: num
                     -2.522 -2.281 -1.176 1.688 0.179 ...
##
  $ T3_3H_R1: num
                     -1.797 -1.597 -3.018 1.812 -0.192 ...
##
   $ T3_4H_R1: num
                     -2.967 -2.635 -2.953 1.868 -0.553 ...
##
   $ T3_5H_R1: num
                     -2.99182 -2.42474 -2.96356 2.14249 -0.00553 ...
   $ T3_6H_R1: num
##
                     -2.84 -2.54 -2.49 2.1 2.09 ...
##
   $ T1 1H R2: num
                     -0.25 -0.527 0.303 -0.234 -0.33 ...
  $ T1_2H_R2: num
##
                     -0.2376 -0.3474 0.5477 -0.2899 0.0044 ...
   $ T1 3H R2: num
                     -0.741 -0.64 0.589 0.725 0.171 ...
## $ T1_4H_R2: num
                     0.504 0.274 -0.908 -0.488 -0.53 ...
  $ T1 5H R2: num
                     0.355 0.347 -1.428 -0.289 -0.481 ...
##
   $ T1 6H R2: num
                     0.698 0.663 -0.699 -0.649 -0.714 ...
##
   $ T2 1H R2: num
                     -0.671 -0.67 0.163 0.272 -0.373 ...
## $ T2 2H R2: num
                     -2.489 -2.416 -2.307 1.47 -0.109 ...
   $ T2_3H_R2: num
                     -2.4 -2.21 -2.32 1.83 0.13 ...
##
   $ T2_4H_R2: num
                     -2.552 -2.198 -3.294 1.618 -0.453 ...
   $ T2_5H_R2: num
                    -2.474 -2.238 -2.967 2.191 0.888 ...
##
  $ T2_6H_R2: num
                    -3.14 -2.47 -3.18 2.19 2.18 ...
   $ T3_1H_R2: num
                     -0.62 -0.842 -0.195 0.17 -0.446 ...
##
   $ T3_2H_R2: num
                     -2.7064 -2.4478 -2.1068 1.5124 0.0384 ...
##
   $ T3_3H_R2: num
                    -2.828 -2.552 -2.624 2.051 -0.111 ...
  $ T3_4H_R2: num
                    -2.849 -2.484 -3.024 1.559 -0.222 ...
```

```
$ T3 5H R2: num
                     -2.94 -2.46 -2.81 2.32 1.19 ...
   $ T3_6H_R2: num
                     -3.39 -2.97 -2.7 2.16 1.95 ...
   $ ExpT1
              : chr
                     "Non" "Non" "Non" "Non" ...
                     "Sous" "Sous" "Sur" ...
   $ ExpT2
##
              : chr
                     "Sous" "Sous" "Sur" ...
    $ ExpT3
              : chr
##
                                            T1_3H_R1
                                                                T1_4H_R1
       T1_1H_R1
                          T1_2H_R1
   Min.
         :-3.58436
                       Min.
                              :-4.3034
                                         Min.
                                                :-2.26607
                                                             Min.
                                                                    :-2.56731
                       1st Qu.:-0.1404
    1st Qu.:-0.22978
                                         1st Qu.:-0.28249
                                                             1st Qu.:-0.42895
   Median :-0.03631
                       Median: 0.1420
                                         Median :-0.05927
                                                             Median: 0.16867
          :-0.02951
   Mean
                       Mean
                             : 0.1767
                                         Mean
                                                : 0.04103
                                                             Mean
                                                                   : 0.05281
    3rd Qu.: 0.12204
                       3rd Qu.: 0.3904
                                         3rd Qu.: 0.15839
                                                             3rd Qu.: 0.44483
                             : 7.2821
##
   Max.
          : 5.06654
                       Max.
                                         Max.
                                                : 6.61788
                                                             Max. : 6.87671
                         T1_6H_R1
##
       T1_5H_R1
                                           T2_1H_R1
                                                               T2 2H R1
##
           :-5.5106
                            :-2.9759
                                               :-4.30401
                                                                   :-4.5825
                      Min.
                                        Min.
    1st Qu.:-0.4788
                      1st Qu.:-0.6124
                                        1st Qu.:-0.43935
                                                            1st Qu.:-0.9932
##
   Median :-0.1984
                      Median :-0.3724
                                        Median: 0.13065
                                                            Median: 0.3289
                            :-0.2416
                                                                 : 0.4714
##
   Mean
           :-0.1585
                                              : 0.06039
                      Mean
                                        Mean
                                                            Mean
    3rd Qu.: 0.2077
                      3rd Qu.: 0.2413
                                        3rd Qu.: 0.46011
                                                            3rd Qu.: 1.9464
##
   Max.
           : 5.8582
                            : 4.1009
                                        Max.
                                              : 8.66345
                                                            Max.
                                                                 : 8.7483
                      Max.
##
       T2_3H_R1
                         T2_4H_R1
                                             T2_5H_R1
                                                                T2_6H_R1
##
   Min.
          :-6.6293
                           :-5.813548
                                                 :-5.8017
                                                                    :-5.6784
                                          Min.
                                                             Min.
    1st Qu.:-2.0451
                      1st Qu.:-2.406108
                                          1st Qu.:-2.4172
                                                             1st Qu.:-2.5552
   Median : 0.3733
                                                             Median: 1.8857
##
                      Median: 0.008421
                                          Median: 0.7556
##
   Mean
          : 0.3805
                      Mean : 0.197409
                                          Mean
                                                : 0.1521
                                                             Mean
                                                                   : 0.2313
##
    3rd Qu.: 2.7644
                      3rd Qu.: 2.699218
                                          3rd Qu.: 2.5236
                                                             3rd Qu.: 2.7235
   Max.
          : 8.9881
                      Max. : 7.503939
                                          Max.
                                                : 7.0606
                                                             Max.
                                                                   : 8.8815
       T3_1H_R1
                         T3_2H_R1
##
                                           T3_3H_R1
                                                             T3_4H_R1
##
          :-2.9561
                            :-4.9884
                                              :-5.8280
                                                                :-6.0789
   Min.
                      Min.
                                        Min.
                                                          Min.
    1st Qu.:-0.4409
                      1st Qu.:-1.1066
                                        1st Qu.:-1.5925
                                                           1st Qu.:-2.4930
                      Median : 0.6914
                                        Median : 0.9585
   Median : 0.1573
                                                           Median: 0.9982
   Mean
         : 0.1714
                      Mean
                            : 0.5878
                                        Mean
                                              : 0.6387
                                                           Mean
                                                                : 0.2736
##
    3rd Qu.: 0.6673
                      3rd Qu.: 2.3016
                                        3rd Qu.: 2.7533
                                                           3rd Qu.: 2.7854
##
          : 8.6849
                            : 8.6560
                                              : 8.0950
                                                           Max. : 7.0103
                      Max.
                                        Max.
##
       T3_5H_R1
                                                              T1_2H_R2
                        T3_6H_R1
                                          T1_1H_R2
##
   Min.
          :-6.910
                     Min.
                            :-4.7625
                                       Min.
                                              :-2.11580
                                                           Min.
                                                                  :-2.75004
##
    1st Qu.:-2.487
                     1st Qu.:-2.0911
                                       1st Qu.:-0.28225
                                                           1st Qu.:-0.27271
                     Median: 1.8690
                                       Median :-0.02432
                                                           Median :-0.04075
   Median : 1.156
##
          : 0.258
                           : 0.3913
                                             :-0.04445
                                                                : 0.10717
   Mean
                     Mean
                                       Mean
                                                           Mean
    3rd Qu.: 2.709
                     3rd Qu.: 2.4879
##
                                       3rd Qu.: 0.15670
                                                           3rd Qu.: 0.25383
##
   Max.
          : 6.529
                     Max. : 8.6398
                                       Max.
                                              : 4.70943
                                                           Max. : 7.03638
##
       T1_3H_R2
                         T1_4H_R2
                                            T1_5H_R2
                                                               T1_6H_R2
##
          :-3.2539
                                                                  :-2.4863
   Min.
                      Min. :-3.50770
                                         Min.
                                                :-3.3307
                                                            Min.
##
    1st Qu.:-0.1229
                      1st Qu.:-0.51001
                                         1st Qu.:-0.6437
                                                            1st Qu.:-0.9686
##
   Median : 0.2674
                      Median :-0.27091
                                         Median :-0.3845
                                                            Median :-0.7215
          : 0.3033
                           :-0.02457
                                                                 :-0.3082
   Mean
                      Mean
                                         Mean
                                               :-0.2410
                                                            Mean
##
   3rd Qu.: 0.5068
                      3rd Qu.: 0.27652
                                         3rd Qu.: 0.1442
                                                            3rd Qu.: 0.5814
##
                      Max. : 6.52284
   Max.
          : 7.1995
                                         Max. : 5.2469
                                                            Max. : 3.9054
##
       T2_1H_R2
                          T2_2H_R2
                                            T2_3H_R2
                                                              T2_4H_R2
##
          :-2.38587
   Min.
                       Min.
                              :-5.8266
                                         Min. :-4.6135
                                                            Min.
                                                                  :-6.4553
##
    1st Qu.:-0.48477
                       1st Qu.:-1.2309
                                         1st Qu.:-1.4511
                                                            1st Qu.:-2.3416
##
   Median : 0.03105
                       Median: 0.6644
                                         Median : 0.5351
                                                            Median : 0.5323
          : 0.08932
                            : 0.4684
                                         Mean : 0.5999
                                                            Mean : 0.1279
   Mean
                       Mean
    3rd Qu.: 0.61495
                       3rd Qu.: 2.1298
                                         3rd Qu.: 2.5954
                                                            3rd Qu.: 2.4618
```

```
Max. : 8.8928
                                       Max. : 8.4956
                                                        Max. : 8.0010
   Max. : 8.59820
##
      T2_5H_R2
                       T2_6H_R2
                                         T3_1H_R2
                                                           T3_2H_R2
         :-6.1685
                     Min. :-6.2234
                                           :-3.22436
                                                        Min. :-6.0944
   1st Qu.:-2.4058
                     1st Qu.:-2.6251
                                      1st Qu.:-0.61705
                                                        1st Qu.:-1.3567
##
   Median : 1.0892
                    Median : 2.0014
                                      Median : 0.07589
                                                        Median: 0.7670
##
   Mean
         : 0.1411
                    Mean : 0.1572
                                      Mean : 0.11618
                                                        Mean
                                                             : 0.5725
   3rd Qu.: 2.5033
                     3rd Qu.: 2.5375
                                      3rd Qu.: 0.76673
                                                        3rd Qu.: 2.3150
                     Max. : 8.7777
   Max. : 7.4521
                                      Max. : 8.77729
                                                        Max. : 8.6354
##
##
      T3_3H_R2
                       T3_4H_R2
                                         T3_5H_R2
                                                          T3_6H_R2
##
         :-6.0135
                     Min. :-6.0345
                                      Min. :-6.8294
                                                             :-7.24672
   Min.
                                                       Min.
   1st Qu.:-1.8079
                     1st Qu.:-2.2277
                                      1st Qu.:-2.5646
                                                       1st Qu.:-2.80051
   Median : 1.1183
                     Median : 1.1769
                                      Median : 1.6539
                                                       Median: 1.92082
##
         : 0.5828
                                                       Mean : 0.05484
                     Mean : 0.3157
                                      Mean : 0.1338
##
   Mean
   3rd Qu.: 2.8892
                     3rd Qu.: 2.6455
                                      3rd Qu.: 2.5664
                                                       3rd Qu.: 2.46450
##
   Max.
         : 8.2637
                     Max.
                          : 7.4777
                                      Max. : 6.9137
                                                       Max. : 8.69285
##
    ExpT1
               ExpT2
                         ExpT3
##
   Non:441
              Non : 11
                        Non: 7
                         Sous:247
   Sous: 57
              Sous:247
              Sur :284
                        Sur :288
##
   Sur : 44
##
##
##
```

Le chargement a nécessité le package : corrplot

corrplot 0.95 loaded

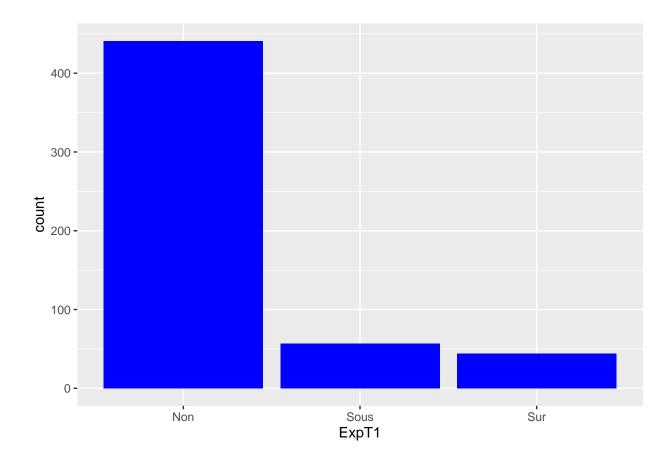


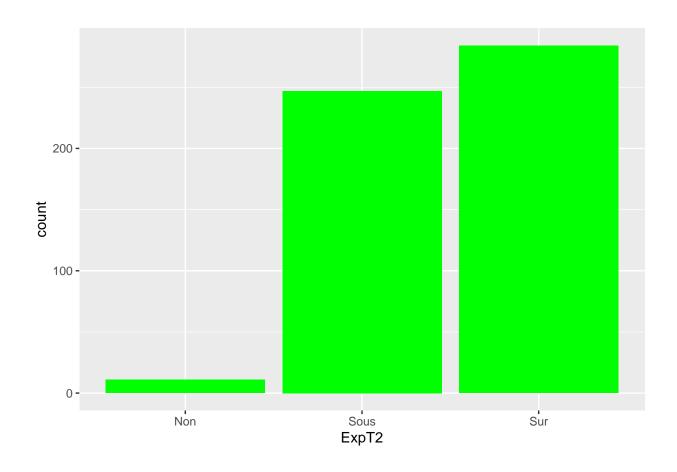
Faites une analyse uni-dimensionnelle et bi-dimensionnelle du jeu de données. Certaines variables sont-elles liées? Une attention particulière sera portée sur le choix des représentations, et sur l'interprétation des résultats présentés. (Voilà ce que j'ai fais pour l'analyse uni-dimensionnelle. Je vais essayer de tout regrouper dans un seul graphe (je n'y arrive pas pour l'instant mais je vais continuer à essayer))

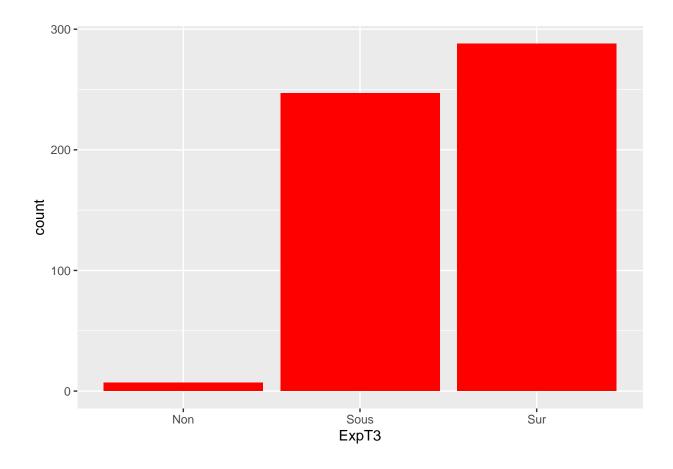
Le chargement a nécessité le package : grid

Le chargement a nécessité le package : gridExtra

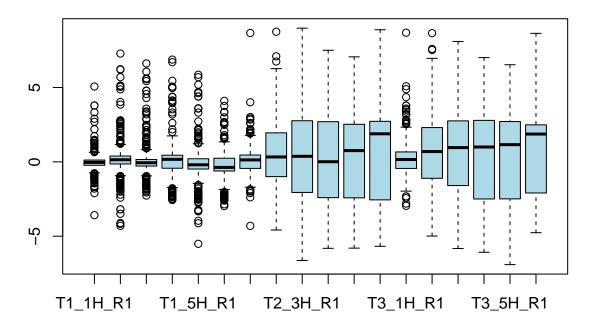
Le chargement a nécessité le package : lattice



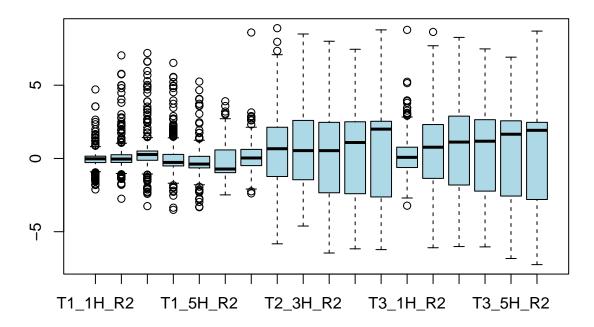




Expression sous T1



Expression sous T1



Interprétation des Résultats (analyse uni-dimensionnelle): À la suite de cette analyse, plusieurs observations et conclusions peuvent être tirées sur les relations entre les variables : (on rappelle que T3 est une combinaison de T1 et T2, indiqué dans le sujet.) En ce qui concerne l'analyse Uni-dimensionnelle sur les variables qualitatives, les fréquences des gènes classés comme surexprimés, sous-exprimés et non exprimés sont globalement similaires pour ExpT2 et ExpT3. Cela peut s'expliquer par le fait que T3 est une combinaison de T1 et T2, ce qui entraîne des distributions proches. En revanche, ExpT1 se distingue clairement des deux autres, la majorité des gènes dans ExpT1 sont non exprimés, ce qui contraste avec les répartitions plus équilibrées observées pour ExpT2 et ExpT3. Cette observation suggère que le traitement T1 induit très peu de changements dans l'expression des gènes en réponse à un traitement.

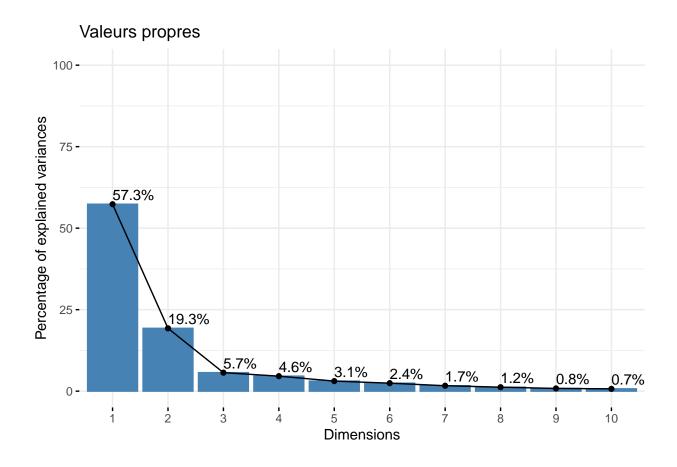
Pour les variables quantitatives, on remarque plusieurs choses. Premièrement, on remarque que les distributions des valeurs d'expression pour R1 et R2 sont remarquablement similaires. Cela indique une bonne reproductibilité biologique entre les réplicats. La cohérence entre R1 et R2 valide la qualité des données et leur fiabilité pour les analyses ultérieures. Pour les traitements, T2 et T3 sont fortement liés, leurs médianes, leurs intervalles interquartiles sont très similaires. Cela renforce l'idée que T3, étant une combinaison de T1 et T2, hérite principalement des caractéristiques de T2. Cependant, les colonnes T2_1H_R1/R2 et T3_1H_R1/R2 présentent un grand nombre de valeurs aberrantes (outliers), ce qui peut indiquer des réponses génétiques atypiques à 1 heure pour ces traitements. Les intervalles interquartiles pour T1 sont beaucoup plus petits, suggérant que les données pour ce traitement sont plus concentrées autour de la médiane. Toutefois, T1 présente également de nombreux outliers, en plus grand nombre que pour T2 ou T3, ce qui peut indiquer des comportements génétiques spécifiques ou une variabilité accrue pour certains gènes sous ce traitement.

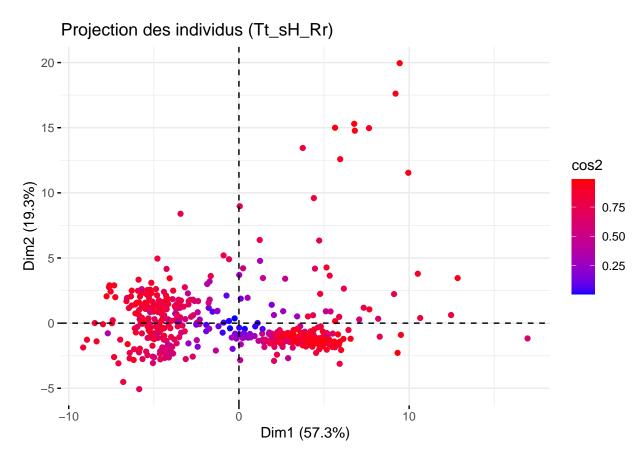
Menez une analyse en composantes principales où les Tt sH Rr sont les individus d'ecrits par les gènes.

Le chargement a nécessité le package : FactoMineR

Le chargement a nécessité le package : factoextra

##			•	percentage			cumulative	percentage	of	
##	comp		20.643727183			.34368662				57.34369
##	${\tt comp}$		6.938281435			27300398				76.61669
##	${\tt comp}$		2.041274447			67020680				82.28690
##	${\tt comp}$		1.656135505			60037640				86.88727
##	${\tt comp}$		1.109348959		3.	.08152489				89.96880
##	${\tt comp}$		0.881791877		2.	44942188				92.41822
##	comp	7	0.599431245		1.	66508679				94.08331
##	${\tt comp}$	8	0.436409980			21224994				95.29556
##	${\tt comp}$	9	0.300326182		0.	.83423939				96.12980
##	${\tt comp}$	10	0.254557652		0.	70710459				96.83690
##	${\tt comp}$	11	0.195646575		0.	54346271				97.38036
	${\tt comp}$		0.114623243			.31839790				97.69876
##	${\tt comp}$	13	0.113438274		0.	31510632				98.01387
##	${\tt comp}$	14	0.098934866		0.	27481907				98.28869
##	${\tt comp}$	15	0.084015374		0.	23337604				98.52206
##	comp	16	0.075403512		0.	20945420				98.73152
##	comp	17	0.068914101		0.	19142806				98.92295
##	comp	18	0.060357899		0.	16766083				99.09061
##	comp	19	0.056624240		0.	15728956				99.24790
##	comp	20	0.045538131		0.	12649481				99.37439
##	comp	21	0.037080890		0.	.10300247				99.47739
##	comp	22	0.032099053		0.	.08916404				99.56656
##	comp	23	0.026356683		0.	.07321301				99.63977
##	comp	24	0.021809019		0.	.06058061				99.70035
##	comp	25	0.015239265		0.	04233129				99.74268
##	comp	26	0.014299054		0.	.03971959				99.78240
##	comp	27	0.011721521		0.	03255978				99.81496
##	comp	28	0.010954844		0.	.03043012				99.84539
##	${\tt comp}$	29	0.009729805		0.	.02702724				99.87242
##	comp	30	0.009492364		0.	.02636768				99.89879
##	comp	31	0.008089909		0.	.02247197				99.92126
##	comp	32	0.006904142		0.	.01917817				99.94044
##	comp	33	0.006571646		0.	01825457				99.95869
##	comp	34	0.005669160		0.	.01574767				99.97444
##	comp	35	0.004995223		0.	01387562				99.98831
##	comp	36	0.004206745		0.	01168540			:	100.00000

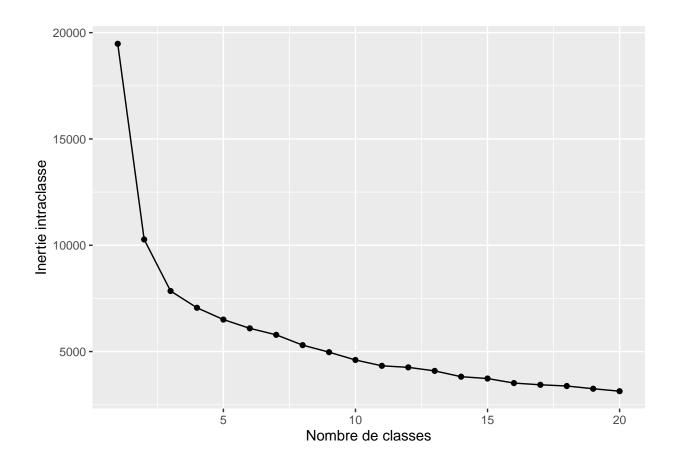




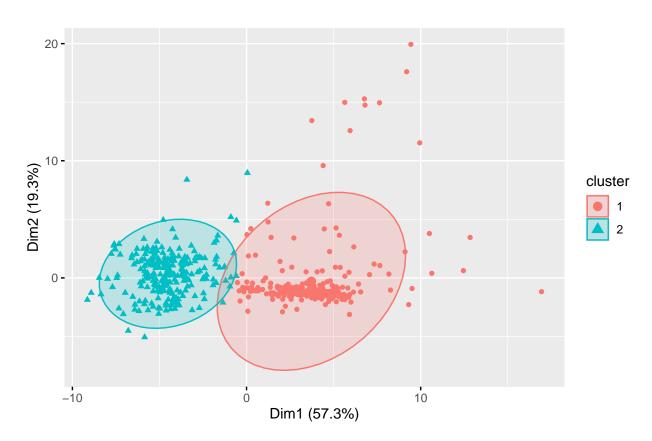
Faites une classification non supervisée (clustering) de ces données afin de regrouper les Tt sH Rr. en plusieurs classes homog'enes.

```
if (!require("forcats")) install.packages("forcats")
if (!require("ggplot2")) install.packages("ggplot2")
if (!require("corrplot")) install.packages("corrplot")
if (!require("FactoMineR")) install.packages("FactoMineR")
if (!require("factoextra")) install.packages("factoextra")
if (!require("mclust")) install.packages("mclust")
if (!require("cluster")) install.packages("cluster")
if (!require("ppclust")) install.packages("ppclust")
if (!require("circlize")) install.packages("circlize")
if (!require("ggalluvial")) install.packages("ggalluvial")
library(forcats)
library(ggplot2)
library(corrplot)
library(reshape2)
library(FactoMineR)
library(factoextra)
library(mclust)
library(cluster)
library(ppclust)
library(circlize)
```

```
library(ggalluvial)
# Maintenant que l'ACP a été effectuée, on fait un clustering des classes à l'aide de la méthode K-mean
# Avant de débuter le clustering avec la méthode K-means, il faut déterminer le nombre de classes.
Kmax<-20
reskmeanscl<-matrix(0,nrow=nrow(DataBio),ncol=Kmax-1)</pre>
Iintra<-NULL</pre>
for (k in 1:Kmax){
  resaux<-kmeans(DataBioCR,centers=k)</pre>
  reskmeanscl[,k-1]<-resaux$cluster</pre>
  Iintra <- c(Iintra, resaux $tot. withinss) # tot. withinss correspond à la somme des composantes au carré d
}
df<-data.frame(K=1:20, Iintra=Iintra)</pre>
ggplot(df,aes(x=K,y=Iintra))+
  geom_line()+
  geom_point()+
  xlab("Nombre de classes")+
  ylab("Inertie intraclasse")
```



Avec cette méthode, on dirait que le coude correspond lorsque le nombre de classes est de 2. # On va alors utiliser 2 classes pour la méthode des K-means.



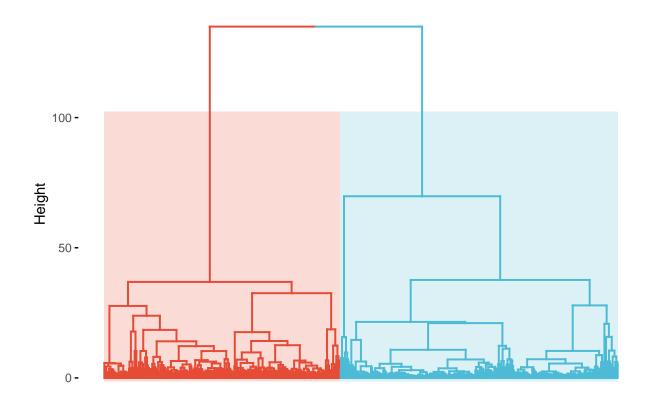
```
#fviz_pca_ind(resacp,col.ind=as.factor(reskmeans$cluster),geom = c("point"),axes=c(1,2))

# A présent, on va essayer une autre méthode, la méthode hiérarchique.

# D'une part, on fait le calcul de la matrice de distances
dist_matrix <- dist(DataBioCR, method = "euclidean")

# Clustering hiérarchique avec la méthode de liaison "ward.D2", on peut aussi faire avec "single", "comp
hc <- hclust(dist_matrix, method = "ward.D2")

# Afficher le dendrogramme
fviz_dend(hc,k=2,show_labels = FALSE,
rect = TRUE, rect_fill = TRUE,palette = "npg",
rect_border = "npg",
labels_track_height = 0.8)+ggtitle("")</pre>
```



(Le temps de chargement est plutôt long, C'est NORMAL)

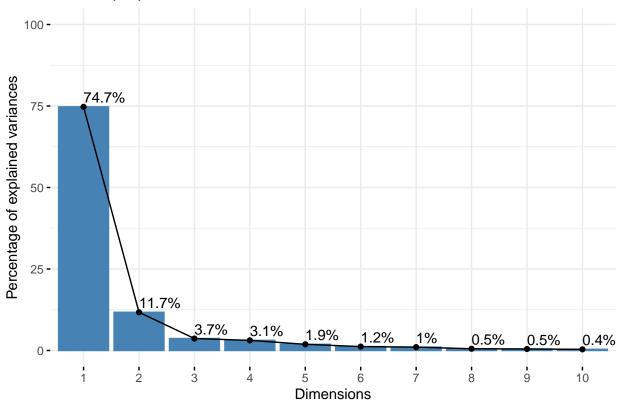
Préliminairement, construisez un jeu de données Data Exp
Moy contenant la moyenne des expressions sur les réplicats de chaque g'ene, pour chaque traitement et chaque heure. Data Exp
Moy est donc une matrice de taille $G \times 18$. Vous pourrez utiliser les variables
 ExpT1, ExpT2 et ExpT3 pour commenter vos résultats des questions suivantes.

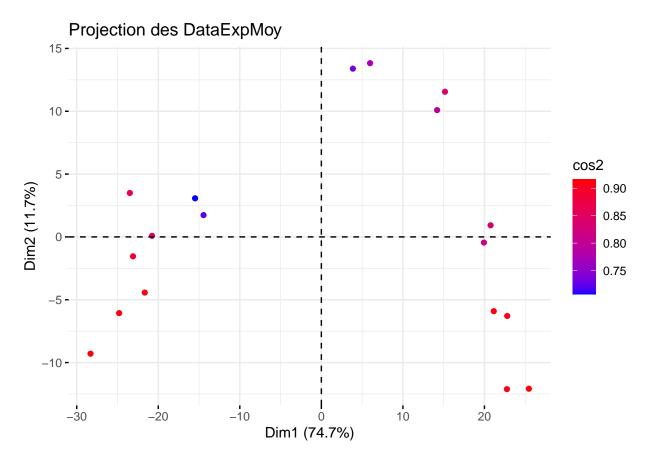
Menez une analyse en composantes principales pour les gènes à partir du jeu de données DataExpMoy.

```
## [1] 542 18
## Warning in mean.default(DataExpMoy_full[DataExpMoy_full$ExpT1 == "Sur", :
## l'argument n'est ni numérique, ni logique : renvoi de NA
## [1] NA
##
            eigenvalue percentage of variance cumulative percentage of variance
## comp 1
           405.0981814
                                   74.74136189
                                                                         74.74136
                                   11.72443541
            63.5464399
                                                                         86.46580
## comp 2
## comp 3
            19.8878459
                                    3.66934427
                                                                         90.13514
                                    3.10848248
                                                                         93.24362
## comp 4
            16.8479751
## comp 5
            10.2927617
                                    1.89903352
                                                                         95.14266
## comp 6
             6.4759341
                                    1.19482180
                                                                         96.33748
## comp 7
             5.5998433
                                    1.03318142
                                                                         97.37066
             2.8740502
                                    0.53026756
                                                                         97.90093
## comp 8
```

##	comp	9	2.4754020	0.45671624	98.35764
##	comp	10	1.9014013	0.35081205	98.70846
##	comp	11	1.6037165	0.29588865	99.00435
##	comp	12	1.4238320	0.26269962	99.26704
##	comp	13	1.1833848	0.21833668	99.48538
##	comp	14	0.9911234	0.18286410	99.66825
##	comp	15	0.7400607	0.13654256	99.80479
##	comp	16	0.5887171	0.10861938	99.91341
##	comp	17	0.4693307	0.08659237	100.00000

Valeurs propres

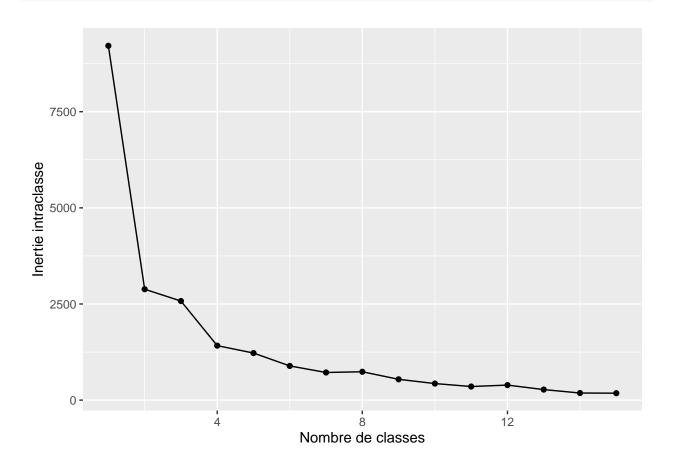




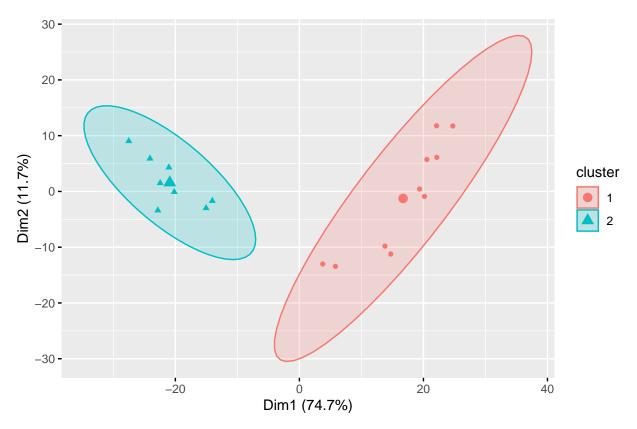
Faites une classification non supervisée (clustering) des gènes à partir de leur expression (DataExpMoy) afin d'obtenir des classes de gènes homogènes (ayant la même évolution d'expression).

```
if (!require("forcats")) install.packages("forcats")
if (!require("ggplot2")) install.packages("ggplot2")
if (!require("corrplot")) install.packages("corrplot")
if (!require("FactoMineR")) install.packages("FactoMineR")
if (!require("factoextra")) install.packages("factoextra")
if (!require("mclust")) install.packages("mclust")
if (!require("cluster")) install.packages("cluster")
if (!require("ppclust")) install.packages("ppclust")
if (!require("circlize")) install.packages("circlize")
if (!require("ggalluvial")) install.packages("ggalluvial")
library(forcats)
library(ggplot2)
library(corrplot)
library(reshape2)
library(FactoMineR)
library(factoextra)
library(mclust)
library(cluster)
library(ppclust)
library(circlize)
```

```
library(ggalluvial)
# Maintenant que l'ACP a été effectuée, on fait un clustering des classes à l'aide de la méthode K-mean
# Avant de débuter le clustering avec la méthode K-means, il faut déterminer le nombre de classes.
Kmax < -15
reskmeanscl<-matrix(0,nrow=nrow(DataExpMoyCR),ncol=Kmax-1)</pre>
Iintra<-NULL</pre>
for (k in 1:Kmax){
  resaux<-kmeans(DataExpMoyCR,centers=k)</pre>
  reskmeanscl[,k-1]<-resaux$cluster</pre>
  Iintra<-c(Iintra,resaux$tot.withinss) # tot.withinss correspond à la somme des composantes au carré d</pre>
df<-data.frame(K=1:15, Iintra=Iintra)</pre>
ggplot(df,aes(x=K,y=Iintra))+
  geom_line()+
  geom_point()+
  xlab("Nombre de classes")+
  ylab("Inertie intraclasse")
```



Avec cette méthode, on dirait que le coude correspond lorsque le nombre de classes est de 2. # On va alors utiliser 2 classes pour la méthode des K-means.



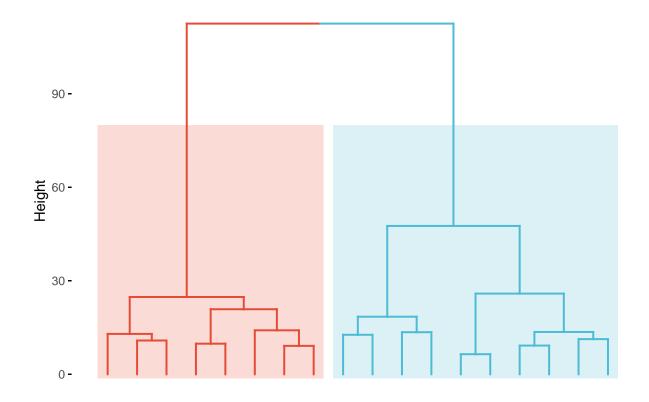
```
#fviz_pca_ind(resacp,col.ind=as.factor(ExpMoykmean$cluster),geom = c("point"),axes=c(1,2))

# A présent, on va essayer une autre méthode, la méthode hiérarchique.

# D'une part, on fait le calcul de la matrice de distances
dist_matrix_ExpMoy <- dist(DataExpMoyCR, method = "euclidean")

# Clustering hiérarchique avec la méthode de liaison "ward.D2", on peut aussi faire avec "single", "com
hc_ExpMoy <- hclust(dist_matrix_ExpMoy, method = "ward.D2")

# Afficher le dendrogramme
fviz_dend(hc_ExpMoy,k=2,show_labels = FALSE,
rect = TRUE, rect_fill = TRUE,palette = "npg",
rect_border = "npg",
labels_track_height = 0.8)+ggtitle("")</pre>
```



(Le temps de chargement est plutôt long)

Faites une classification non supervisée (clustering) des gènes à partir des variables ExpT1, ExpT2 et ExpT3. Comparez avec les résultats de la question précédente.